

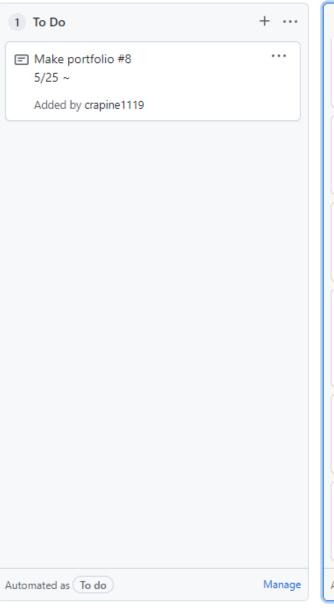
GENESISLAB

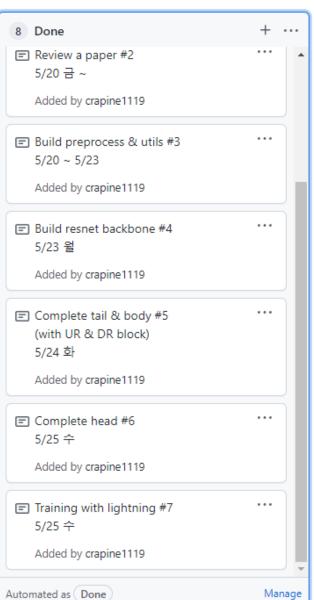
S.H.KIM

CONTENTS

- 0. 작업 순서
- 1. 논문 리뷰
- 2. 코드 구현
- 3. 개선 사항

작업 순서

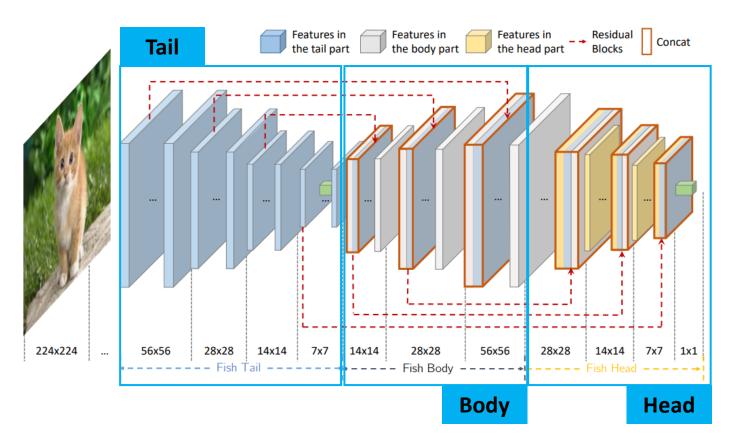




- 요약
- Object Detection & Segmentation network의 장점을 통합한 backbone 개발 (Escape from Classification backbone!)
- Direct gradient propagation from deep to shallow layers
- 연구 목적
- 1. Versatile backbone
- Image(I) level : Classification > 연속적 Downsample > Deep feature but low resolution (Region/Pixel level에 부적합)
- R/P level : Detection/Segmentation > Down/Upsample > Deep feature with high resolution (U-Net, FPN etc.)
- ▶ I/R/P level의 장점을 통합한 Backbone??

2. Direct gradient propagation

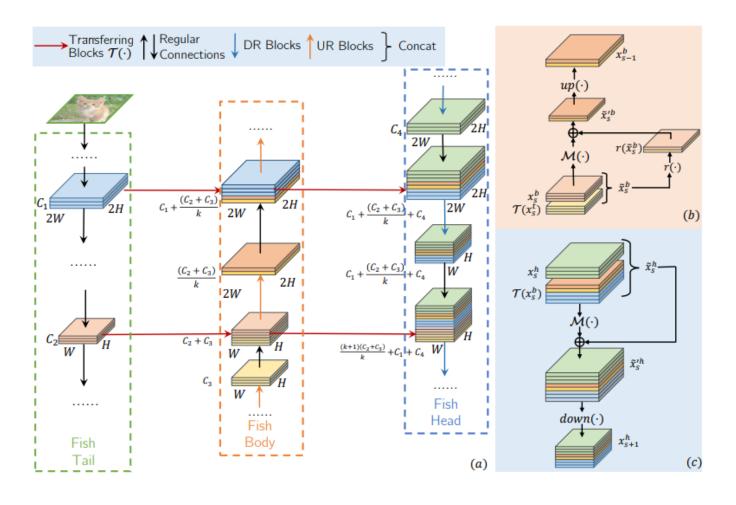
- Identity mapping(residual block or concatenation)의 문제점?
- > Resolution이 변하면서 convolution (Isolated-convolution)을 이용 : Direct gradient propagation를 방해
- ➤ Direct gradient propagation을 위한 네트워크 구조 변경



- > Tail: Deep (high-level semantic meaning) low-resolution feature
- > Body: High resolution with high level semantic information
- > Head : Feature Preserving/Refining/Unifying > Do task

FishNet Structure

- 같은 크기의 feature를 "stage"라고 정의
- 같은 Stage의 I/R/P level feature를 모두 concatenation (붉은색 점선)
- Direct propagation을 통해 semantic meaning을 네트워크 전반에 걸쳐 유지
- Feature Refining을 통해 Deep/Shallow feature간 상호작용

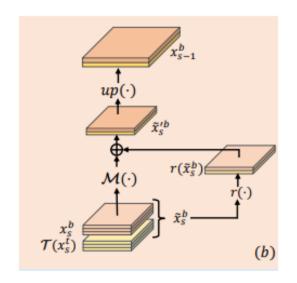


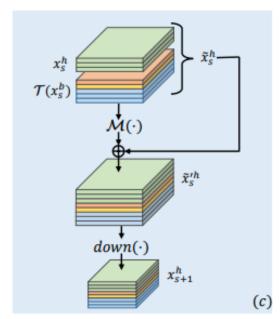
Details

- 검은 선 : Identity mapping

$$x_{L_s,s} = x_{0,s} + \sum_{l=1}^{L_s} \mathcal{F}(x_{l,s}, W_{l,s}), \quad \frac{\partial \mathcal{L}}{\partial x_{0,s}} = \frac{\partial \mathcal{L}}{\partial x_{L_s,s}} (1 + \frac{\partial}{\partial x_{0,s}} \sum_{l=1}^{L_s} \mathcal{F}(x_{l,s}, W_{l,s}))$$

- 붉은 선 : Transferring block (residual block)
- 주황선: Upsample & Refinement (Concat > Refinement > Nearest upsample)
- 파랑 선 : Downsample & Refinement (Concat > Refinement > Maxpool 2x2)





(b) UR block

$$x_{s-1}^b = UR(x_s^b, \mathcal{T}(x_s^t)) = up(\tilde{x}_s^{\prime b})$$

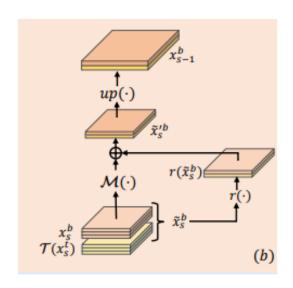
- M(x): BottleNeck residual unit (conv1x1 > conv3x3 > conv1x1)
- r(x): Element wise summation (adjacent k)
- up(・): Nearest upsample (scale 2.0) (Upsampled feature는 dilated convolution으로 해결)

(c) DR block

$$x_{s+1}^h = down(\tilde{x}_s^{\prime h}),$$

- down (•): Maxpool 2x2 (stride 2)

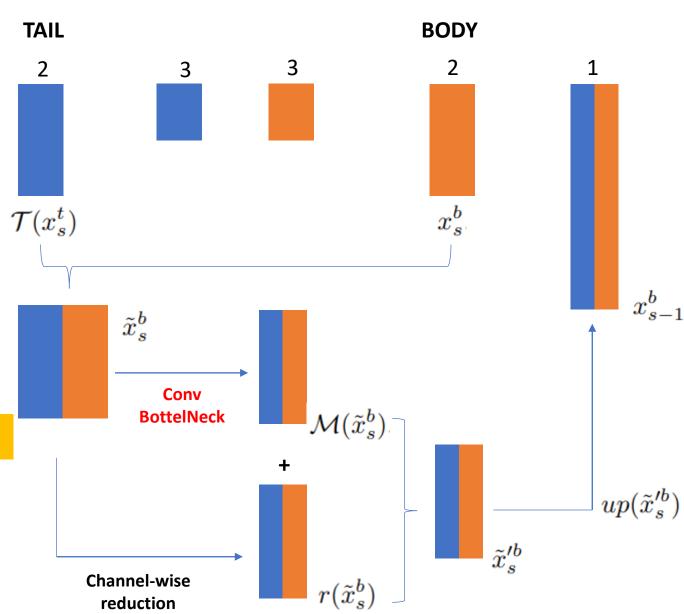
• 이해하기 위한 과정

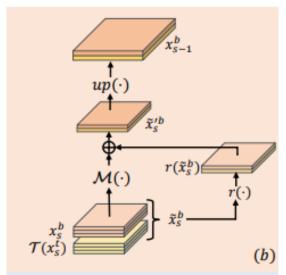


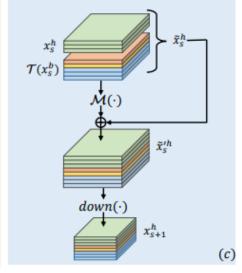
(4)
$$x_{s-1}^b = UR(x_s^b, \mathcal{T}(x_s^t)) = up(\tilde{x}_s'^b)$$

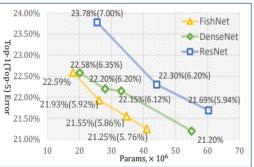
이부분에서 Bn구조를 썼으면 완전한 Direct인가..?

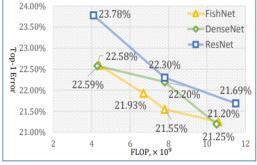
S=1











- 이러한 구조의 장점
- 더 적은 파라미터로도 좋은 accuracy
- ▶ 보존/정제된 Feature의 상호작용이 Width/Depth를 늘리는 것보다 효과적이기 때문
- Body/Head에서 I-Conv를 이용하지 않음
- ➤ Direct BP를 통해 성능을 향상
- I/R/P level의 feature를 모두 고려
- ➤ High resolution & Deep feature가 반영된 backbone network
- ▶ Detection/Segmentation 성능 향상

(전체 논문 내용 리뷰)

https://github.com/crapine1119/fishnet/blob/main/REVIEW.md

1. Data Read & Check

https://github.com/crapine1119/fishnet

데이터를 읽고, make_grid 함수를 이용해서 이미지를 확인

```
# http://www.cs.toronto.edu/~kriz/cifar.html
Def unpickle(file):
    with open(file, 'rb') as fo:
        dict = pickle.load(fo, encoding='bytes')
    fo.close()
    return dict
# torchvision.utils.make_grid
def check img(rdir):
    files = glob('%s/*data_batch*'%rdir)
    assert len(files)>0, 'No file error'
    d = unpickle(files[0])
    imgset flat = d[b'data']
    imgset = imgset flat.reshape(-1, 3, 32, 32)
    batch = torch.LongTensor(imgset[:64])
    plt.figure(figsize=[18,8])
    plt.imshow(make grid(batch, padding=2).permute(1, 2, 0).numpy())
def load_cifar(rdir):
    trn_files = glob('%s/*data_batch*'%rdir)
    assert len(trn_files)>0, 'No file error'
    tst file = '%s/test_batch'%rdir
    # train set
    trnx,trny = [],[]
    for fnm in trn_files:
        batch = unpickle(fnm)
        trnx.append(batch[b'data'])
        trny.extend(batch[b'labels'])
    trnx = np.concatenate(trnx).reshape(-1,3,32,32)
    trny = np.array(trny)
    # test set
    batch = unpickle(tst_file)
    tstx = batch[b'data'].reshape(-1,3,32,32)
    tsty = np.array(batch[b'labels'])
    return trnx, tstx, trny, tsty
```

<u>코드 구현</u>

2. Implement details & Custom dataset

- Image size = 32x32
- Augmentation: Random resize crop (32), Horizontal flip, Fancy PCA
- Optimizer : Adam
- SGD의 학습 속도가 너무 느려서 변경
- Learning rate / weight decay = 1e-2 / 1e-4
- 30 epochs마다 1/10로 감소
- Batch size : 256
- Normalize [0,1]
- Subtracting mean and divide by std
- Loss function = CrossEntropy

```
class custom(Dataset):
   def __init__(self, imgs, labels, trans):
        super().__init__()
        self.imgs =imgs
        self.labels = labels
        self.trans = trans
    def __len__(self):
        return len(self.labels)
    def __getitem__(self, item):
        img = self.imgs[item]
        img = np.transpose(img, (1,2,0))
        label = self.labels[item]
        mat = \{\}
        img = self.trans(image=img)['image']
        mat['img'] = torch.FloatTensor(img)
        mat['label'] = torch.LongTensor([label])
        return mat
```

3. Make ResNet backbone for Tail

```
class BN_block(nn.Module):
   def __init__(self, in_c, out_c, stride, bottleneck, dilation, se, preact):
       super().__init__()
       self.bottleneck = bottleneck
       self.bn_c = int(out_c/bottleneck)
       self.se = se
       self.preact = preact
       if preact:
                                                  pre-activation 유무에 따라
           self.conv1 = (...)
                                                  Conv, Batch, ReLU 순서 변경
           self.conv1 = (...)
           self.bridge = SE_block(out_c, out_c)
                                                Tail과 Body를 연결하기 위한 SE block
       self.relu = nn.ReLU(inplace=True)
       self.shortcut = nn.Sequential()
       if (stride != 1) | (in_c != out_c):
           self.shortcut = nn.Conv2d(in_c, out_c, kernel_size=1, stride=stride, bias=False)
   def forward(self, x):
       if self.se:
           feature_map = self.conv(x)
           x = self.shortcut(x) + feature_map*self.bridge(feature_map)
           x = self.shortcut(x) + self.conv(x)
       if not self.preact:
           x = self.relu(x)
```

Bottleneck block: Tail/Body/Head에 모두 이용, pre-activation on/off 가능

SE block: Bottleneck 구현이 끝난 후, 쉽게 추가할 수 있도록 구성

class SE_block(nn.Module): def __init__(self, in_c, out_c, reduction_rate=16): Squeeze > FC > Unsqueeze

Identity mapping with pre-activation & SE block

```
super().__init__()
bn_c = int(in_c / reduction_rate)
self.se_net = nn.Sequential(nn.AdaptiveAvgPool2d(1), # squeeze
nn.Conv2d(in_c, bn_c, kernel_size=1, stride=1, bias=False),
nn.ReLU(),
nn.Conv2d(bn_c, out_c, kernel_size=1, stride=1, bias=False),
nn.Sigmoid()) # excitation
```

def forward(self,x):
 return self.se_net(x)

return x

3. Make ResNet backbone for Tail

Layer stacking (make_layer)함수를 정의하고 Tail/ module을 완성

Upsample은 Stage가 바뀔 경우 한번만 수행되기 때문에 첫 블록에만 dilated convolution을 할 수 있도록 만들었습니다.

```
def make_layer(block, in_c, out_c, repeat, dilation=1, last=None, preact=Irue):
    stacked = []
    for i in range(repeat):
       if i==0:
           stacked.append(block(in_c, out_c, dilation=dilation, stride=1, preact=preact)
            stacked.append(block(out_c, out_c, dilation=1, stride=1, preact=preact))
   if last is not None:
       stacked.append(last)
   return nn.Sequential(*stacked)
                       2번의 Bottleneck unit은 BN_block.conv를 재활용하였습니다.
class tail(nn.Module):
   def __init__(self, in_c, out_c, model, Ls='3,4,6,3', num_c='64,128,256,512', preact=True):
       super().__init__()
       (...)
       if preact:
            self.conv1 = nn.Sequential(nn.Conv2d(in_c, self.num_c[0], kernel_size=3,
                                               stride=1, padding=1, bias=False),
                                      BN_block(self.num_c[0], self.num_c[0], preact=preact).conv,
                                      BN_block(self.num_c[0],self.num_c[0],preact=preact).conv)
       else:
         self.conv1 = nn.Sequential(BN_block(in_c,
                                                           self.num_c[0], preact=preact).conv,
                                    BN_block(self.num_c[0], self.num_c[0], preact=preact).conv)
Stage 구분
       self.t1 = make_layer(BN_block, self.num_c[0], self.num_c[1], repeat=self.Ls[0],
                            preact=preact, last=nn.MaxPool2d(kernel_size=2,stride=2,padding=0))
```

self.t2 = make_layer(BN_block, self.num_c[1], self.num_c[2], repeat=self.Ls[1],

self.t3 = make_layer(BN_block, self.num_c[2], self.num_c[3], repeat=self.Ls[2],

preact=preact, last=nn.MaxPool2d(kernel_size=2,stride=2,padding=0))

preact=preact, last=nn.MaxPool2d(kernel_size=2,stride=2,padding=0))

모델 이름을 지정하여 Tail/ResNet 자유롭게 전환 가능

3. Make ResNet backbone for Tail

완성한 ResNet/Tail 구조

```
resnet(
(conv1):
  (0~1)Residual_block
                                Stage에 따라 3,4,6,3개의 block을 stack
 (t1): Sequential(
  (0~2): BN block
                                기존 ResNet과 다르게 Stride Convolution
  (3): MaxPool2d)
                                대신 Maxpool을 이용
 (t2): Sequential(
  (0 \sim 3): BN block
  (4): MaxPool2d)
 (t3): Sequential(
  (0~5): BN block
  (6): MaxPool2d)
 (t4): Sequential(
  (0~2): BN_block
  (3): Sequential(
    (0): AdaptiveAvgPool2d
    (1): squeeze()
    (2): Linear(in_features=512, out_features=10, bias=True)))
                                  Tail은 마지막 Stage의
```

return

4. Make Pipeline by pytorch-lightning

Layer stacking (make_layer)함수를 정의하고 Tail module을 완성한 뒤 Pytorch lightning을 이용하여 전체적인 학습 파이프라인을 구성

```
class fishnet(nn.Module):
   def __init__(self, hparams):
       super(). init ()
            self.tail = tail(in c, block, Ls tail)
            # self.body = body
            # self.head = head
   def forward(self,x1):
                                         처음 생각한 모델 구조는
       x2 = self.tail(x1)
                                         Input x1와 Tail/Body의 output x2,x3를
       \# x3 = self.body(x2)
       \# out = self.head(x1,x2,x3)
                                         Head로 전달하는 방식
       # out = self.classification(out)
    return out
def make fish(hparams):
                             Argparse를 통해 모델 생성
   return fishnet(hparams)
class net(LightningModule):
   def __init__(self, hparams):
       super().__init__()
       self.save_hyperparameters(hparams)
       self.fish = make_fish(hparams)
       self.init_weights()
                                      생성한 FishNet을 통해 학습 진행
   def forward(self,x):
       out = self.fish(x)
       return out
   def loss f(self, modely, targety):
       f = nn.CrossEntropyLoss()
       return f(modely, targety)
   def init_weights(self):
   def configure_optimizers(self):
       return
   def step(self, x):
```

5. Make Body & Head

return x r * k

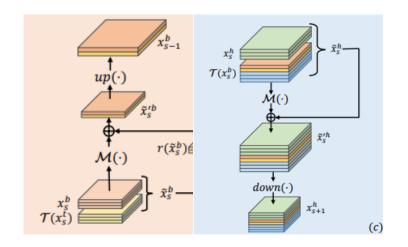
Body와 Head에 이용하기 위한 Up/Down sample(UDR) block을 구현

```
class UDR_block(nn.Module):
    def __init__(self, in_c=1024,k=2, phase='up', preact=True):
        super().__init__()
        self.phase=phase
   if phase=='up':
                                                     BottleNeck unit을 통해
        self.M = BN_block(in_c, int(in_c/k),
                          preact=preact).conv
                                                     Feature Refinement 수행
    else:
        self.M = BN_block(in_c, in_c,
                                                     (Upsample은 reduction rate 적용)
                           preact=preact).conv
        self.upsample = nn.Upsample(scale_factor=2, mode='nearest')
        self.dwsample = nn.MaxPool2d(kernel size=2, stride=2, padding=0)
        self.avgpool = nn.Sequential(nn.AdaptiveAvgPool2d(1),
                                      squeeze())
    def forward(self,x):
        if self.phase=='up':
            x_new = self.M(x) + self.r_func(x)
            x \text{ new} = \text{self.upsample}(x \text{ new})
        elif self.phase=='down':
            x \text{ new} = x + \text{self.M}(x)
            x \text{ new} = \text{self.dwsample}(x \text{ new})
                                                     채널을 합칠 때 파라미터 사이즈를
        elif self.phase=='last':
            x \text{ new} = x + \text{self.M}(x)
                                                     줄이기 위한 channel-wise
            x \text{ new} = \text{self.avgpool}(x \text{ new})
                                                     (AvgPool을 통해 간단히 구현)
        return x_new
    def r_func(self, x, k=2):
        :param x: tensor {n,c,h,w}
        :param k: int
        :return: x with reduced dimension
        _{,} c, h, w = x.size()
        x_{-} = x.contiguous().view(-1, c, h * w)
        x_r_ = nn.AvgPool1d(kernel_size=k, stride=k)(x_.permute(0, 2, 1))
        x_r = x_r_{permute(0, 2, 1).contiguous().view(-1, int(c / k), h, w)
```

5. Make Body & Head

Transferring, Regular Connections, Concatenation을 수행하는 모듈 구성

```
class CAT_block(nn.Module):
   def __init__(self, in_c, add_c, dilation=1, repeat=1, k=2, phase='up', preact=True):
       super().__init__()
       self.phase=phase
                            Body/Head<sup>□</sup> Regular connection (Identity mapping)
       self.regular = make_layer(BN_block, in_c, in_c, repeat=repeat, dilation=dilation,
                                preact=preact)
       self.transfer = block(add_c, add_c).conv
       self.sample = UDR_block(in_c+add_c, BN_block, k=k, phase=phase)
   def forward(self,x,x_add):
       :param x:
                                                        같은 Stage의 feature를 전달
       :param x add:
       :return: tuple (concatenated, sampled)
       x = self.regular(x) # input
       x_add = self.transfer(x_add)
       x_{new} = concat(x, x_{add})
       out = self.sample(x_new)
       if self.phase=='up':
                                                   아래의 그림을 구현하고
           return x_new, out
                                                   Resolution이 바뀐 feature를
           return out
                                                   다음 Stage로 전달하는 과정
```



5. Make Body & Head

Body와 Head를 따로 구현하려다 보니 Forward 부분이 불필요하게 복잡해졌고, 이를 해결하기 위해 두 모듈을 동시에 구현

Number of stacked layers in Body & Head

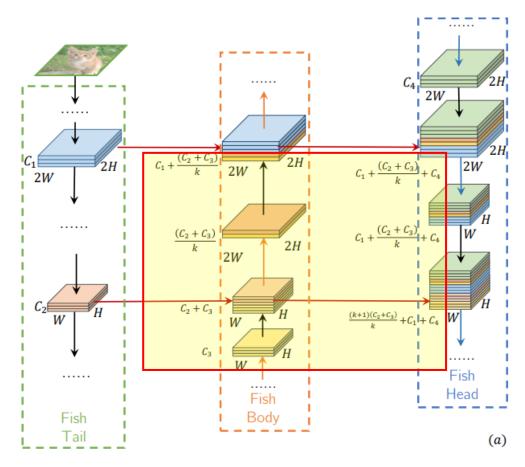
Number of channels in Tail

```
class body_head(nn.Module):
   def __init__(self, k, preact, Ls_body='1,1,1', Ls_head='1,1,1,1')
                                                                     num_c = '64,128,256,512'):
       super().__init__()
       self.Ls_body = [*map(int,Ls_body.split(','))]
       self.Ls_head = [*map(int,Ls_head.split(','))]
       self.in_c, self.added_c = auto_calcul(num_c, k)
       self.b4 = CAT_block(self.in_c[0]
                                          self.added_c[0], repeat=self.Ls_body[0], phase='up',
                                          k=k, preact=preact)
       self.b3 = CAT_block(self.in_c[1]
                                          self.added_c[1], repeat=self.Ls_body[1], phase='up',
                                          k=k, preact=preact, dilation=2)
       self.b2 = CAT_block(self.in_c[2]
                                          self.added_c[2], repeat=self.Ls_body[2], phase='up',
                                          k=k, preact=preact, dilation=4)
                                                               Dilated convolution 구현
       # head
       self.h1 = CAT_block(self.in_c[3]
                                          self.added_c[3], repeat=self.Ls_head[0],phase='down',
                                          k=k, preact=preact)
       self.h2 = CAT_block(self.in_c[4]
                                          self.added_c[4], repeat=self.Ls_head[1],phase='down',
                                          k=k, preact=preact)
       self.h3 = CAT_block(self.in_c[5]
                                          self.added_c[5], repeat=self.Ls_head[2],phase='down',
                                          k=k, preact=preact)
       self.h4 = CAT_block(self.in_c[6]
                                          self.added_c[6], repeat=self.Ls_head[3],phase='last',
                                          k=k, preact=preact)
   def forward(self, x):
       _ , x3_ = self.b4(x['bridge'], x['4\])
       x3, x2_{=} = self.b3(x3_{,} x['3']) # cated, sampled
       x2, out =self.b2(x2_, x['2'])
       out = self.h1(out, x['1'])
       out = self.h2(out, x2)
       out = self.h3(out, x3)
       out = self.h4(out, x['4'])
       return out
                                       Channel 수를 조절할 때마다
```

Channel 수를 소설할 때마다 직접 계산해줘야 하는 문제가 발생

6. Channel calculation

아래의 그림을 보고, Tail의 채널만 정해주면 자동으로 계산하는 함수 구현



Regular Connection에 의한 채널 수(검은 선)

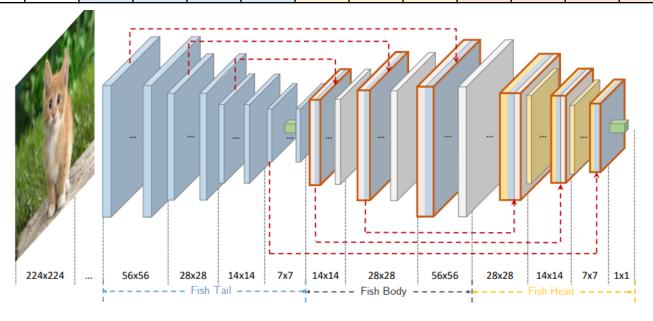
```
def auto_calcul(num_c = '64,128,256,512', k=2):
    num_c = [*map(int,num_c.split(','))]
    in added = \lceil num \ c \lceil -1 \rceil \rceil
    for i in range(3):
        in_added.append(int((in_added[i] + num_c[-i - 1]) / k))
    in_added.append(int((in_added[3] + num_c[0])))
    num_c.append(in_added[2] + num_c[1])
                                            Tail 또는 Body에서 전달되는
    num_c.append(in_added[1] + num_c[2])
   num_c.append(num_c[3])
                                            Feature의 채널 수(붉은 선)
    for i in range(4, 7):
        in added.append(in added[i] + num c[i])
                                                       Body / Head에서
    return in_added, num_c[3::-1]+num_c[4:]
                                                       Stage가 역전됨을 고려
```

7. FishNet

Tail/Body/Head 모듈을 받아 FishNet99를 구성하고 Classification을 수행

* FishNet99

	First Layer	T1	Т2	Т3	T4	B4	В3	B2	H1	H2	Н3	H4
Output Size	32	32	16	8	4	8	16	32	16	8	4	1
Blocks	2	3	4	6	3	1	1	1	1	1	1	1
Layers	7	9	12	18	11	6	6	6	6	6	6	6



8. The number parameters & FLOP

https://github.com/sovrasov/flops-counter.pytorch를 이용하여,

구현한 ResNet50과 FishNet99를 확인

* The number parameters & FLOP

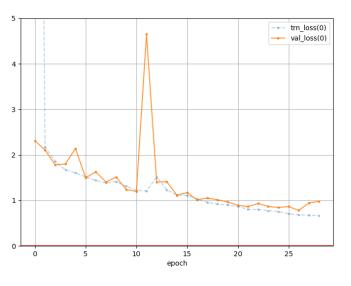
	FLOP (1e+9)	Params (1e+6)			
ResNet50	0.56	3.00			
FishNet99	2.53	17.92			

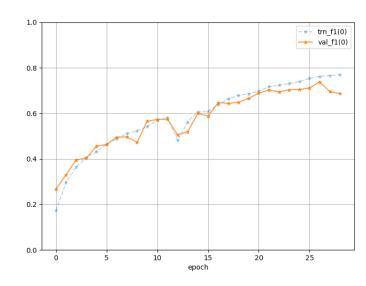
9. Test

Top 1 & 5 error 확인 : 약 30 epoch 기준으로 27.0 (1.7)%를 기록

```
def get_err(model, hparams, ckp, tst_loader):
    model = model.load_from_checkpoint(checkpoint_path=ckp, hparams=hparams)
    model.cuda()
    model.eval()
    num1, numk=0, 0
    n dset = 0
    for i in tqdm(tst_loader):
        with torch.no_grad():
            ans = model(i['img'].cuda())
        _,top1 = ans.topk(1,dim=-1)
        _,top5 = ans.topk(5,dim=-1)
        num1+=(top1.cpu()==i['label']).squeeze().sum().item()
        numk+=(top5.cpu()==i['label']).any(dim=1).sum().item()
        n_dset+=len(top1)
    return {'top1':num1/n_dset,
            'top5':numk/n dset}
```

* Loss plot





개선 사항

• r(x): Element wise summation

$$r(x) = \hat{x} = [\hat{x}(1), \hat{x}(2), \dots, \hat{x}(c_{out})], \quad \hat{x}(n) = \sum_{j=0}^{k} x(k \cdot n + j), n \in \{0, 1, \dots, c_{out}\}, \quad (8)$$

- 간단한 식이지만 전개할 때 이상함을 느꼈습니다.
- k개의 element-wise summation을 나타내려면 우측 식의 붉은 박스에서 k를 k-1로 수정해야 합니다.
- 좌측 식과 우측 식의 n의 수가 일치하지 않습니다.

개선 사항

- Backbone for Object detection & Segmentation?
 - R/P level을 고려하기 위한 네트워크지만 Classification backbone 구조를 차용한 점이 모순적입니다. 이를 해결하기 위한 새로운 Tail 구조가 필요하다고 생각합니다.
 - R/P level에 집중하기 위해 Tail에 남아있는 I-conv 대신, Channel에 upsample을 적용하는 방법을 제안합니다.
 - 코드를 구현하면서 Tail과 Body를 연결하는 부분의 Identity mapping이 적절치 않다는 생각이 들었습니다.
 SE_block을 이용하지 않고 마지막 Stage를 보존하는 것이 direct gradient propagation에 효과적일 것 같습니다.

• 느낀점

- Direct propagation을 통해 R/P level meaning을 더 효과적으로 포착할 수 있다는 점이 놀랍습니다.
- 구조의 변경함으로써 성능을 개선할 뿐 아니라, 그것의 의미를 찾고자 한 의미있는 논문이었습니다.